

Classificação de Termografias Mamárias com Vision Transformer e CNN: uma Abordagem de Mineração de Dados e Aprendizado Profundo

*Trabalho desenvolvido para a disciplina de Mineração de Dados

1st Gustavo Pioli Resende
FACOM - Faculdade de Computação
Universidade Federal de Uberlândia (UFU)
Uberlândia, Brazil
gustavo.pioli@ufu.br

Abstract—O câncer de mama é uma das principais causas de morte por câncer entre mulheres, e a mamografia, embora seja o padrão-ouro de rastreamento, perde sensibilidade em pacientes jovens e com mamas densas. Este trabalho investiga o uso da termografia infravermelha, base de dados DMR-IR, como fonte de dados alternativa para a detecção precoce da doença, combinando técnicas exploratórias de mineração de dados com modelos de aprendizado profundo. Inicialmente, características estatísticas de histograma e de textura (GLCM) foram extraídas e projetadas em duas dimensões via t-SNE, revelando forte sobreposição entre as classes *Healthy* e *Sick* quando descritas por métricas globais, o que motivou o uso de modelos capazes de aprender representações diretamente da imagem. Foram treinados e comparados, sob protocolo experimental idêntico, um modelo *Vision Transformer* (*vit_tiny_patch16_224*) e uma CNN *DenseNet121*, ambos por *transfer learning* com validação cruzada estratificada por grupos (*Stratified Group 5-Fold*), garantindo que imagens do mesmo paciente não fossem simultaneamente utilizadas em treino e validação. Na configuração inicial, com apenas pesos de classe na função de perda, o ViT atingiu acurácia média de 87,7% e a *DenseNet121*, 87,2%, mas ambos com sensibilidade limitada à classe *Sick* (recall de 59% e 57%, respectivamente), refletindo o forte desbalanceamento da base (3454 imagens *Healthy* contra 790 *Sick*). Para mitigar esse problema, aplicou-se um *WeightedRandomSampler* a nível de amostra, combinado à seleção do melhor checkpoint por F1-score da classe minoritária. Essa estratégia elevou o F1-score de *Sick* de 0,64 para 0,70 no ViT (recall de 73%) e de 0,62 para 0,65 na *DenseNet121* (recall de 72%), com o ViT preservando sua acurácia geral (88,4% média nos folds), enquanto a CNN cedeu cerca de 1,7 ponto percentual de acurácia para obter ganho semelhante de sensibilidade. Os resultados indicam que o balanceamento a nível de amostra é mais determinante para a sensibilidade à classe clínica de interesse do que a escolha entre CNN e ViT, e que o ViT absorve esse balanceamento de forma mais estável.

Index Terms—termografia infravermelha, câncer de mama, mineração de dados, Vision Transformer, aprendizado profundo, DMR-IR

I. INTRODUÇÃO

O câncer de mama é o tipo de câncer mais diagnosticado entre as mulheres nos Estados Unidos e a segunda principal causa de morte por câncer nesse grupo. Em 2026, a *American*

Cancer Society estima 321.910 novos casos de câncer de mama invasivo e 42.140 óbitos pela doença no país [1]. No Brasil, o INCA projeta 78.610 novos casos por ano no triênio 2026–2028, com risco nacional de 71,57 por 100 mil mulheres (chegando a 88,29 no Sudeste); em 2023, a doença causou 20.165 óbitos no país [2]. O diagnóstico precoce reduz a mortalidade e amplia as opções de tratamento [2]. Entre as técnicas de diagnóstico, a mamografia é a mais utilizada, com sensibilidade de até 90% em mulheres mais velhas, mas de apenas cerca de 60% em pacientes mais jovens [3]. Essa limitação motiva a busca por abordagens alternativas, como a termografia infravermelha, capaz de detectar alterações metabólicas e vasculares associadas a tecidos cancerosos [4].

Este trabalho tem como objetivo aplicar um pipeline de mineração de dados sobre a base pública DMR-IR (*Database for Mastology Research with Infrared Image*) [5], composta por termogramas de pacientes saudáveis e com patologias mamárias, e avaliar comparativamente o uso de um modelo *Vision Transformer* (ViT) e de uma CNN convolucional clássica (*DenseNet121*) para a classificação binária das imagens. A hipótese investigada é a de que o mecanismo de auto-atenção do ViT é mais adequado para capturar padrões térmicos sutis e distribuídos por toda a imagem, em vez de padrões estritamente locais como os aprendidos por filtros convolucionais, e que essa diferença arquitetural pode ser especialmente relevante em um cenário de forte desbalanceamento de classes, onde a base de dados dispõe de poucos exemplos da classe patológica.

II. TRABALHOS RELACIONADOS

A base DMR-IR foi construída pelo projeto PROENG e é a base pública mais utilizada em pesquisas de classificação de câncer de mama a partir de termogramas [5]. Diversos trabalhos exploraram essa base combinando extração de características estatísticas e de textura (histograma, matriz de ocorrência de níveis de cinza - GLCM) com classificadores clássicos, como SVM e árvores de decisão, obtendo acurácias na faixa de 84% a 88% quando avaliados sobre o conjunto

completo de imagens, sem necessariamente isolar os pacientes entre treino e teste.

Com a popularização do aprendizado profundo, modelos baseados em CNN, como ResNet, DenseNet e EfficientNet, passaram a ser aplicados à termografia mamária, geralmente por meio de *transfer learning* a partir de pesos pré-treinados na ImageNet, dado o tamanho reduzido da base DMR-IR. Mais recentemente, arquiteturas baseadas em *Vision Transformer* (ViT), originalmente propostas por Dosovitskiy et al. [6], vêm sendo investigadas como alternativa às CNNs em diversas tarefas de imagem médica, incluindo termografia mamária. Garia e Hariharan [7], por exemplo, aplicaram Vision Transformers para classificação de câncer de mama a partir de imagens térmicas, reportando resultados competitivos com os obtidos por CNNs tradicionais e destacando a capacidade do mecanismo de auto-atenção de relacionar regiões distantes da imagem, algo que filtros convolucionais locais capturam com mais dificuldade.

O presente trabalho se diferencia por conduzir, antes da etapa de classificação, uma análise exploratória de mineração de dados (histograma de intensidade, descritores GLCM e projeção t-SNE) especificamente sobre a base DMR-IR utilizada, com o objetivo de verificar empiricamente a separabilidade das classes por métricas estatísticas globais e, a partir desse diagnóstico, justificar a escolha de modelos capazes de aprender representações diretamente da imagem. Além disso, este projeto conduz um comparativo direto entre ViT e DenseNet121 sob o mesmo protocolo experimental e realiza ainda um estudo de ablação sobre o efeito de uma estratégia de balanceamento a nível de amostra (*WeightedRandomSampler*), isolando tanto o efeito da arquitetura quanto o efeito da estratégia de balanceamento sobre a sensibilidade à classe minoritária.

III. MATERIAIS E MÉTODOS


A. Base de Dados

Foi utilizada a base pública DMR-IR [5], composta por imagens termográficas mamárias, capturadas nos modos estático e dinâmico para pacientes classificados como *Healthy* (saúdável) ou *Sick* (com alguma patologia mamária). Para cada paciente, foi selecionada as imagens correspondentes ao protocolo de captura frontal, evitando a duplicidade de ângulos de captura (frontal, laterais a 45° e 90°) para a mesma sessão.

Após o processamento da estrutura de diretórios da base, foram obtidas as estatísticas apresentadas na Tabela I. A base é fortemente desbalanceada: pacientes saudáveis correspondem a aproximadamente 80,7% dos pacientes e 81,4% das imagens, o que exige cuidados específicos tanto na divisão dos dados quanto na função de perda utilizada no treinamento.

TABLE I: Estatísticas da Base de Dados DMR-IR Utilizada

Classe	Pacientes	Imagens	Imagens/paciente
Healthy	192	3454	18,0
Sick	46	790	17,2
Total	238	4244	17,8



(a) Healthy

(b) Sick

Fig. 1: Exemplos de termogramas da base DMR-IR: (a) paciente da classe Healthy; (b) paciente da classe Sick.

B. Análise Exploratória e Mineração de Dados

Antes de aplicar qualquer técnica de aprendizado de máquina, realizou-se uma etapa de mineração exploratória para caracterizar estatisticamente as classes e avaliar a viabilidade de separá-las por meio de descritores clássicos de imagem.

1) *Histograma de intensidade*: para cada imagem, em escala de cinza, calculou-se o histograma de 256 níveis, normalizado pelo número de pixels da imagem. Em seguida, calculou-se a média desses histogramas para cada classe, resultando na Fig. 2. Observa-se que ambas as classes concentram a maior parte da massa de probabilidade nos tons intermediários de cinza, com curvas médias muito próximas entre Healthy e Sick, indicando alta similaridade estatística global entre pacientes saudáveis e doentes em termos de distribuição bruta de temperatura.




Fig. 2: Histograma térmico médio por classe (Healthy vs. Sick).

2) *Descritores de textura (GLCM)*: para quantificar a organização espacial dos tons térmicos, calculou-se a Matriz de Co-ocorrência de Níveis de Cinza (GLCM) de cada imagem (distância 1, ângulo 0°), da qual foram extraídas as métricas de contraste, energia, homogeneidade e correlação. A distribuição dessas métricas por classe é apresentada na Fig. 3.

Os resultados mostram que o contraste é baixo para ambas as classes, o que é esperado em imagens térmicas com transições suaves de temperatura. A correlação entre pixels vizinhos é próxima de 1,0 em quase todas as amostras, indicando ausência de ruído do tipo sal-e-pimenta. As métricas




Fig. 3: Distribuição dos descritores de textura GLCM (contraste, energia, homogeneidade e correlação) por classe.

de energia e homogeneidade, por sua vez, apresentam mediana ligeiramente superior no grupo Sick, sugerindo que regiões afetadas por processos patológicos tendem a formar áreas termicamente mais uniformes (possivelmente associadas a regiões de hipertermia focal), enquanto o grupo saudável apresenta maior variabilidade espacial da temperatura ao longo do corpo.

3) *Redução de dimensionalidade (t-SNE)*: os vetores de histograma (256 dimensões) e GLCM (4 dimensões) foram concatenados, padronizados (*z-score*) e projetados em duas dimensões via t-SNE (*perplexity* = 30), resultando na Fig. 4.

A projeção evidencia forte sobreposição entre as classes Healthy e Sick, sem formação de agrupamentos distintos. Esse resultado indica que descritores estatísticos globais (histograma e GLCM) não são suficientes para separar linearmente as classes. Esse diagnóstico foi o principal motivador metodológico para a adoção de um modelo de aprendizado profundo capaz de aprender representações não lineares diretamente a partir dos pixels da imagem, em vez de depender de características estatísticas pré-definidas.

C. Modelo ViT

Para a classificação das imagens termográficas, optou-se pela arquitetura Vision Transformer, especificamente a variante *vit_tiny_patch16_224*. A seleção deste modelo justifica-se pelo cenário de restrição volumétrica do dataset, dado que versões mais robustas (e.g., ViT-Base) apresentam severa propensão




Fig. 4: Projeção t-SNE (2D) dos vetores de histograma + GLCM.

ao *overfitting* em ambientes com escassez de amostras. Com aproximadamente 5,7 milhões de parâmetros e operando com resolução nativa de 224×224 pixels divididos em *patches* de 16×16 , a arquitetura Tiny oferece um balanço computacional ótimo, viabilizando o mecanismo de *self-attention*

em hardware restrito, ao mesmo tempo em que se beneficia do pré-treinamento na base ImageNet para a extração de características texturais e de contraste térmico.

A escolha do ViT em detrimento de uma CNN é reforçada diretamente pelos resultados da análise exploratória: como a sobreposição entre classes ocorre mesmo em nível de estatísticas globais, presume-se que a distinção real dependa de padrões distribuídos por regiões não contíguas da imagem (por exemplo, assimetria térmica entre a mama esquerda e a direita). O mecanismo de auto-atenção do ViT relaciona diretamente qualquer par de *patches* da imagem, independentemente da distância espacial entre eles, o que o torna teoricamente mais apto a capturar esse tipo de dependência de longo alcance do que os filtros convolucionais de campo receptivo local usados nas CNNs.

D. Modelo CNN

Como *baseline* de comparação, foi treinada a arquitetura DenseNet121, CNN convolucional clássica caracterizada por conexões densas entre camadas (cada camada recebe como entrada os *feature maps* de todas as camadas anteriores), amplamente adotada como referência em tarefas de classificação de imagens médicas, incluindo termografia mamária, conforme discutido na Seção II. Com aproximadamente 8 milhões de parâmetros, a DenseNet121 também foi inicializada com pesos pré-treinados na ImageNet e ajustada por *transfer learning*, sob exatamente o mesmo protocolo experimental do ViT descrito na Seção III-E (mesmos folds, mesma taxa de aprendizado, mesmo otimizador, mesmo *class weighting* e mesmo número de épocas), de modo que as diferenças de desempenho entre os dois modelos possam ser atribuídas à arquitetura, e não a variações no processo de treinamento.

E. Processo de Treinamento e Validação

Para lidar com a base de dados reduzida e desbalanceada, foram adotadas as seguintes estratégias, aplicadas de forma idêntica ao ViT e à DenseNet121, de modo a permitir uma comparação justa entre as arquiteturas. Como o desbalanceamento entre classes representa o principal desafio identificado, o processo de treinamento foi conduzido em duas configurações experimentais, descritas ao final desta seção, para isolar o efeito de estratégias de balanceamento adicionais sobre a sensibilidade à classe minoritária:

- **Validação cruzada estratificada por grupos:** utilizou-se *Stratified Group K-Fold* ($k = 5$), em que o agrupamento (*group*) corresponde ao identificador do paciente. Essa escolha é fundamental para evitar *data leakage*: como cada paciente possui, em média, 17,8 imagens (Tabela I), uma divisão puramente aleatória por imagem poderia colocar fotos do mesmo paciente simultaneamente em treino e validação, inflando artificialmente a acurácia. A estratificação garante ainda que a proporção entre as classes Healthy e Sick seja preservada em cada fold.
- **Balanceamento da função de perda:** como a classe Sick é minoritária (em torno de 19% das imagens), utilizou-se *Cross-Entropy Loss* com pesos por classe calculados de

forma balanceada (*class_weight* = "balanced") a partir da distribuição de cada fold de treino, penalizando mais fortemente os erros na classe minoritária. Essa estratégia esteve presente em ambas as configurações experimentais.

- **Aumento de dados (*data augmentation*):** durante o treino, aplicou-se *RandomResizedCrop* (escala entre 90% e 100% da imagem) e espelhamento horizontal aleatório ($p = 0,5$), gerados dinamicamente a cada época. As imagens de validação foram apenas redimensionadas para 224×224 e normalizadas com média e desvio-padrão da ImageNet, sem *augmentation*. Importante notar que essa técnica, sozinha, ajuda a reduzir *overfitting* nas poucas imagens da classe Sick, mas não corrige o desbalanceamento em si, já que é aplicada igualmente a ambas as classes.
- **Transfer learning e taxa de aprendizado reduzida:** tanto o *vit_tiny_patch16_224* quanto a DenseNet121 foram inicializados com pesos pré-treinados na ImageNet e ajustados com otimizador AdamW, taxa de aprendizado de 3×10^{-5} e *weight decay* de 0,1. A taxa de aprendizado deliberadamente baixa busca preservar o conhecimento pré-treinado e mitigar o *overfitting*, ao qual modelos de grande capacidade como o ViT são particularmente suscetíveis quando ajustados com poucos dados e taxas de aprendizado mais agressivas.
- **Regularização adicional:** *dropout* de 0,3 foi aplicado na camada de classificação do modelo.
- Cada fold foi treinado por 10 épocas, com *batch size* de 16.

A partir dessa base comum, duas configurações experimentais foram avaliadas:

- **Configuração I – sem balanceamento a nível de amostra:** o *DataLoader* de treino utiliza amostragem aleatória uniforme (*shuffle*), de modo que cada imagem tem a mesma probabilidade de ser sorteada em cada época, independentemente da classe. O balanceamento fica a cargo exclusivamente dos pesos de classe na função de perda. O critério de seleção do melhor *checkpoint* de cada fold, nesta configuração, foi a maior acurácia de validação.
- **Configuração II – com balanceamento a nível de amostra:** o *DataLoader* de treino passa a utilizar um *WeightedRandomSampler*, no qual cada amostra recebe peso inversamente proporcional à frequência da sua classe naquele fold de treino (com reposição), fazendo com que imagens da classe Sick sejam sorteadas com maior frequência ao longo de cada época. Nesta configuração, adotou-se como critério final de seleção o F1-score da classe Sick, que só atinge valores altos quando *recall* e precisão estão simultaneamente em níveis razoáveis.

IV. RESULTADOS E DISCUSSÕES

Como discutido na Seção III-E, o processo de treinamento foi conduzido em duas configurações experimentais: uma inicial, apenas com pesos de classe na função de perda (Configuração I), e outra com balanceamento adicional a

nível de amostra via *WeightedRandomSampler* e seleção de *checkpoint* por F1-score de Sick (Configuração II). As duas são apresentadas a seguir, permitindo avaliar isoladamente o efeito da arquitetura (ViT vs. DenseNet121) e o efeito da estratégia de balanceamento.

A. Configuração I: Sem Balanceamento a Nível de Amostra

A Tabela II apresenta a melhor acurácia de validação obtida em cada um dos cinco folds da validação cruzada, para o ViT e para a DenseNet121, treinados sob protocolo idêntico e sem o *WeightedRandomSampler*.

TABLE II: Configuração I – Melhor Acurácia de Validação por Fold: ViT vs. DenseNet121

Fold	ViT-Tiny	DenseNet121
1	88,9%	93,1%
2	90,0%	91,0%
3	84,0%	83,5%
4	85,3%	80,8%
5	90,5%	87,4%
Média	87,7%	87,2%

Consolidando as previsões da melhor época de cada fold em um único conjunto (4244 amostras, correspondente a todo o dataset em regime *out-of-fold*), obtiveram-se os relatórios de classificação apresentados nas Tabelas III e IV. A Fig. 5 e a Fig. 6 trazem as curvas médias de perda/acurácia e a matriz de confusão consolidada de cada modelo nesta configuração.

TABLE III: Configuração I – Relatório de Classificação – ViT-Tiny (Out-of-Fold)

Classe	Precisão	Recall	F1-Score	Suporte
Healthy	0,91	0,94	0,93	3454
Sick	0,70	0,59	0,64	790
Acurácia		0,88		4244
Média macro	0,81	0,77	0,78	4244
Média ponderada	0,87	0,88	0,87	4244

TABLE IV: Configuração I – Relatório de Classificação – DenseNet121 (Out-of-Fold)

Classe	Precisão	Recall	F1-Score	Suporte
Healthy	0,91	0,94	0,92	3454
Sick	0,69	0,57	0,62	790
Acurácia		0,87		4244
Média macro	0,80	0,75	0,77	4244
Média ponderada	0,86	0,87	0,87	4244

Nessa configuração, os dois modelos apresentaram desempenho global muito semelhante: acurácia média de 87,7% (ViT) contra 87,2% (DenseNet121) nos folds de validação, e 88% contra 87% na avaliação consolidada, uma diferença dentro da margem de variação observada entre os próprios folds de cada modelo (por exemplo, o Fold 3 foi o mais difícil para ambas as arquiteturas, com 84,0% e 83,5%, respectivamente). Essa proximidade de resultados é consistente com o diagnóstico da análise exploratória (Fig. 4): tanto o campo

receptivo hierárquico da CNN quanto o mecanismo de auto-atenção do ViT conseguem, na prática, capturar informação suficiente para distinguir a maioria dos casos, dado o mesmo regime de *transfer learning* e o mesmo volume de dados. Em ambos os modelos, porém, a sensibilidade à classe patológica ficou abaixo de 60% de *recall*, e as curvas de treino/validação (Fig. 5 e Fig. 6) mostram estabilização da perda de validação em patamar mais alto que a de treino, um indício de *overfitting*, esperado dado o tamanho reduzido do subconjunto Sick (apenas 46 pacientes).

B. Configuração II: Com Balanceamento a Nível de Amostra

Para mitigar a baixa sensibilidade à classe Sick observada na Configuração I, aplicou-se o *WeightedRandomSampler* descrito na Seção III-E, com seleção do melhor *checkpoint* de cada fold pelo F1-score da classe Sick. A Tabela V apresenta a acurácia de validação e o F1-score de Sick correspondentes ao *checkpoint* selecionado em cada fold.

TABLE V: Configuração II – Acurácia e F1-Score (Sick) do Checkpoint Selecionado por Fold

Fold	ViT-Tiny		DenseNet121	
	Acc.	F1 Sick	Acc.	F1 Sick
1	91,3%	81,8%	92,4%	83,3%
2	89,5%	67,6%	86,8%	69,9%
3	80,3%	56,0%	79,7%	50,9%
4	88,8%	70,6%	79,2%	53,1%
5	91,9%	73,0%	89,3%	66,9%
Média	88,4%	69,8%	85,5%	64,8%

TABLE VI: Configuração II – Relatório de Classificação – ViT-Tiny (Out-of-Fold)

Classe	Precisão	Recall	F1-Score	Suporte
Healthy	0,94	0,92	0,93	3454
Sick	0,67	0,73	0,70	790
Acurácia		0,88		4244
Média macro	0,81	0,82	0,81	4244
Média ponderada	0,89	0,88	0,89	4244

TABLE VII: Configuração II – Relatório de Classificação – DenseNet121 (Out-of-Fold)

Classe	Precisão	Recall	F1-Score	Suporte
Healthy	0,93	0,89	0,91	3454
Sick	0,59	0,72	0,65	790
Acurácia		0,86		4244
Média macro	0,76	0,80	0,78	4244
Média ponderada	0,87	0,86	0,86	4244

Comparando com a Configuração I, o F1-score de Sick subiu de 0,64 para 0,70 no ViT (*recall* de 59% para 73%, precisão recuando de 0,70 para 0,67) e de 0,62 para 0,65 na DenseNet121 (*recall* de 57% para 72%, precisão recuando de 0,69 para 0,59). Notavelmente, o ViT preservou sua acurácia geral (88,4% de média por fold, ante 87,7% na Configuração




Fig. 5: Configuração I – ViT-Tiny: curvas médias de perda e acurácia (treino e validação) e matriz de confusão consolidada.




Fig. 6: Configuração I – DenseNet121: curvas médias de perda e acurácia (treino e validação) e matriz de confusão consolidada.




Fig. 7: Configuração II – ViT-Tiny: curvas médias de perda e acurácia (treino e validação) e matriz de confusão consolidada.




Fig. 8: Configuração II – DenseNet121: curvas médias de perda e acurácia (treino e validação) e matriz de confusão consolidada.

I), enquanto a DenseNet121 cedeu cerca de 1,7 ponto percentual de acurácia (85,5% ante 87,2%) para obter um ganho de sensibilidade semelhante. Esse contraste sugere que o ViT absorve o reforço da classe minoritária de forma mais estável que a CNN: ao ser exposto com mais frequência às imagens Sick, parece redistribuir sua atenção sem comprometer tanto a representação aprendida para a classe Healthy, possivelmente por não depender de um campo receptivo fixo e local como os filtros convolucionais.

V. CONCLUSÃO

Este trabalho aplicou um pipeline de mineração de dados e aprendizado profundo à base pública DMR-IR para a detecção de câncer de mama a partir de termogramas. A etapa exploratória, baseada em histograma de intensidade, descritores de textura GLCM e projeção t-SNE, demonstrou que as classes Healthy e Sick apresentam alta similaridade estatística global, o que motivou tecnicamente a substituição de abordagens estatísticas clássicas por modelos de aprendizado profundo capazes de aprender representações diretamente dos pixels da imagem. Sob um protocolo idêntico de validação cruzada estratificada por paciente, o modelo *vit_tiny_patch16_224* e a DenseNet121 apresentaram desempenho global equivalente quando treinados apenas com pesos de classe na função de perda (87,7% e 87,2% de acurácia média, respectivamente), ambos com sensibilidade limitada à classe patológica (recall abaixo de 60%). A introdução de um *WeightedRandomSampler* a nível de amostra, combinada à seleção do melhor *checkpoint* pelo F1-score da classe Sick, elevou o F1-score de Sick de 0,64 para 0,70 no ViT e de 0,62 para 0,65 na DenseNet121. Notavelmente, o ViT absorveu esse balanceamento sem perda de acurácia geral (88,4% de média por fold, ante 87,7% na configuração original), enquanto a DenseNet121 cedeu cerca de 1,7 ponto percentual de acurácia para obter um ganho de sensibilidade semelhante, sugerindo maior estabilidade do mecanismo de auto-atenção frente à mudança na distribuição de amostras vista durante o treino. Esses resultados contribuem para o entendimento que, para esta base de dados, o balanceamento a nível de amostra e o critério de seleção de *checkpoint* são fatores mais determinantes para a sensibilidade à classe clínica de interesse do que a escolha específica entre CNN e ViT, ainda que sua generalização exija validação em outras bases e configurações. Como trabalhos futuros, propõe-se: (I) a ampliação da base de dados com mais pacientes da classe Sicke (II) a análise dos mapas de atenção do ViT, de modo a interpretar quais regiões térmicas da imagem mais influenciam a decisão do modelo, aproximando a solução de um cenário de uso clínico assistido.

REFERENCES

- [1] R. L. Siegel, T. B. Kratzer, N. S. Wagle, H. Sung, and A. Jemal, "Cancer statistics, 2026," CA: A Cancer Journal for Clinicians, vol. 76, no. 1, e70043, 2026.
- [2] Instituto Nacional de Câncer (Brasil), *Estimativa 2026: Incidência de Câncer no Brasil*. Rio de Janeiro: INCA, 2026. ISBN 978-65-88517-52-9.
- [3] D. Gonçalves, T. Souza, and A. Fernandes, "Limitations of mammography in dense breast tissue and the role of complementary imaging techniques," unpublished (referência a completar pelo autor).
- [4] M. Milosevic, D. Jankovic, and A. Peulic, "Thermography based breast cancer detection using texture features and minimum variance quantization," EXCLI Journal, vol. 13, pp. 1204–1215, 2014.
- [5] L. F. Silva, D. C. M. Saade, G. O. Sequeiros, A. C. Silva, A. C. Paiva, R. S. Bravo, and A. Conci, "A new database for breast research with infrared image", Journal of Medical Imaging and Health Informatics, vol. 4, no. 1, pp. 92–100, 2014.
- [6] A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, M. Dehghani, M. Minderer, G. Heigold, S. Gelly, J. Uszkoreit, and N. Houlsby, "An image is worth 16x16 words: Transformers for image recognition at scale," in Proc. Int. Conf. Learning Representations (ICLR), 2021.
- [7] L. S. Garia and M. Hariharan, "Vision Transformers for Breast Cancer Classification from Thermal Images," in Proc. Int. Conf. Computational Intelligence in Data Science, 2023, pp. 177–185.